

1. Rozszerzony opis wykorzystywanych zbiorów danych

Dane o punktach POI (Google Maps API) Dane o konkurencji i punktach użyteczności publicznej pozyskujemy z Google Maps API (New). Choć dane te są dostępne "na żądanie" w czasie rzeczywistym, nasza architektura stawia na rygorystyczną minimalizację liczby zapytań w celu optymalizacji kosztów. Wykorzystujemy zapytania zdefiniowane przestrzennie, na które nakładamy ściśle filtry kategorii (np. tylko piekarnie i supermarkety) oraz maski pól (FieldMask), dzięki czemu pobieramy wyłącznie niezbędne atrybuty (nazwa, adres, współrzędne GPS). Należy mieć na uwadze ograniczenie samego API, które dla zapytania przestrzennego zwraca maksymalnie 20 wyników.

Dane pogodowe, dane odnośnie deszczu (open-meteo.com) Podczas rozmów z klientem, dotarliśmy do informacji, że proces sprzedażowy wykorzystuje mechanizm zawieszania zamówienia na płocie bądź pozostawienie go w innej formie na zewnątrz przed domem zamawiającego. W związku z powyższym podjęliśmy decyzję biznesową aby nasza hurtownia umożliwiała zestawienie danych sprzedażowych z opadami w godzinach dostarczania zamówień.

Na początku myśleliśmy o uwzględnieniu historycznych zapisów pogodowych dla konkretnych współrzędnych, natomiast po analizie doszliśmy do wniosku, że dużo lepszym predyktorem wpływu pogody na sprzedaż jest nie to jaka faktycznie była pogoda, ale jaka miała być pogoda. Dzięki temu uwzględniamy lepiej to czym się kierowała np. dzień wcześniej większość zamawiających klientów. Dlatego pobierając dane pobieramy informacje na temat prognoz w godzinach 6-10 rano. Zbieramy takie dane jak maksymalne prawdopodobieństwo opadów w tych godzinach, oraz sumę opadów z tych godzin w milimetrach.

2. Opis planowanego procesu ELT ze szczególnym uwzględnieniem sposobu transformacji i integracji danych

2.1 Faza Ekstrakcji

Ekstrakcja następuje z trzech źródeł: baza bake2home, google maps api, oraz open-meteo.

Najpierw sprawdzamy datę ostatniego eksportu i eksportujemy nowe rekordy z każdej tabeli z każdej bazy jako osobne csv.

Zauważmy, że dane z open-meteo oraz google maps api są ściśle powiązane z szerokością i długością geograficzną danych z bake2home. Dlatego w celu optymalnego wykorzystania api najpierw musimy wyeksportować w csv wynik zapytania do bazy bake2home, gdzie prosimy o wszystkie nowe szerokości i długości geograficzne oraz daty, tak żeby wiedzieć dla jakich parametrów ściągać dane z google maps api, oraz open meteo do późniejszej fazy transformacji. Aby to zrobić należy z bazy delivery-manager-db, z tabeli Deliveries należy wziąć int OrderId, i zrobić joina po OrderId z tabelą Bakery Orders z bazy planner-db, tak aby mieć listę deliveries z Date, oraz Latitude oraz Longitude odpowiadającą danym z tabeli FactOrderItem. Następnie na podstawie listy Latitude i Longitude ściągnąć dane z Google Maps API z współrzędnymi wszystkich punktów w okolicy oraz zapisać do pliku CSV:

Kategoria	Nazwa	Adres	Szerokość (Lat)	Długość (Lon)	Typy Google
Piekarnia/Cukiernia	Kołacz na Okrągło Auchan Okęcie	Aleja Krakowska 61, 02-285 Warszawa	52.1711992	20.9346711	bakery, food_store, food, point_of_interest, store, establishment
Supermarket	Biedronka	Sportowa 1, 05-090 Raszyn	52.1536184	20.9217322	discount_supermarket, supermarket, grocery_store, food_store, food, store, establishment

Kategoria	Nazwa	Adres	Szerokość (Lat)	Długość (Lon)	Typy Google
Supermarket	Delikatesy Centrum	Pruszkowska 52, 05-090 Raszyn	52.1612933	20.9147626	grocery_store, supermarket, deli, food_store, food, store, point_of_interest, establishment

Oraz dla każdej listy unikalnych Latitude, Longitude oraz Date, ściągnąć dane z open-meteo do pliku CSV:

Latitude	Longitude	Date	WeatherMorningPrecipProb	WeatherMorningPrecipSumMm
52.1656	20.9326	2026-04-06	72	3.30
52.1656	20.9326	2026-03-26	86	2.90
52.1656	20.9326	2026-03-20	93	0.90

2.2 Faza Ładowania (Big Query)

Wrzucamy wszystkie pliki .csv do bucketu Google Cloud Storage, a następnie tworzymy tabele w bigquery odpowiadające wyeksportowanym wcześniej plikom .csv, oraz dwóm plikom z danymi z google maps, oraz z danymi opadowymi. Finalnie tabele uzupełniamy uploadem .csv z GCS.

2.3 Proces ELT – Faza Transformacji (Google Cloud Dataform)

Transformacja danych surowych w docelowy model wielowymiarowy (Star Schema) odbywa się bezpośrednio w silniku BigQuery za pomocą narzędzia Google Cloud Dataform. Proces obejmuje trzy kluczowe operacje:

Generowanie Kluczy Zastępczych (Surrogate Keys): Dataform generuje unikalne klucze SK_ (typu INT64) dla każdego rekordu wymiaru, wykorzystując natywne funkcje hashujące BigQuery (np. FARM_FINGERPRINT). Uniezależnia to hurtownię od zmian identyfikatorów w systemach źródłowych i zapewnia integralność referencyjną między faktami a wymiarami.

Implementacja Historyzacji (SCD2): Dataform automatycznie zarządza wymiarami wolnozmiennymi Typu 2. W przypadku wykrycia zmiany w atrybutach wymiaru (np. zmiana adresu klienta), stary rekord zostaje "wygaszony" (aktualizacja IS_CURRENT i VALID_TO), a nowy wstawiany z aktualną datą VALID_FROM. Gwarantuje to pełną spójność danych historycznych bez konieczności pisania skomplikowanych zapytań MERGE.

Integracja Wieloźródłowa (Cross-Source Joins & Spatial Analytics): Wewnętrzne dane operacyjne (np. adresy klientów z bazy Bake2Home) są łączone za pomocą Spatial Joinów z zewnętrznymi danymi z Google Maps API (tabela DIM_COMPETITORS). Wykorzystując funkcje GIS (np. ST_DISTANCE), Dataform przelicza zdenormalizowane metryki odległościowe, które trafiają bezpośrednio jako atrybuty analityczne do tabeli DIM_CUSTOMER. Dzięki danym z meteo API dataform przelicza również informację czy zamówienie było dostarczane w deszczowy dzień, informacja ta trafia do tabeli FACT_ORDER_ITEM.

Harmonogram Odświeżania Danych (Data Refresh Strategy)

Procesy ładujące i transformujące są orkiestrowane z różną częstotliwością, aby zapewnić optymalny balans między świeżością danych a kosztami operacyjnymi:

Dane operacyjne (Bake2Home DB): Codziennie w nocy (Daily Nightly Batch). Klasyczny widok "T-1" na wczorajsze zamknięcie dnia, bez obciążania systemów produkcyjnych w godzinach szczytu.

Dane pogodowe: Codziennie nad ranem. Pobieramy prognozę D-1 — czyli to, co modele pogodowe prognozowały wczoraj na dzisiaj (Previous Runs API, parametr previous_model_run=1). Interesuje nas okno godzinowe 6:00–10:00 dla

każdej lokalizacji dostawy.

Dane o konkurencji i POI (Google Maps API): Raz w miesiącu (Monthly). Cykl otwierania i zamykania fizycznych punktów sprzedaży charakteryzuje się niską dynamiką. Miesięczne odświeżanie gwarantuje miarodajny obraz otoczenia rynkowego przy minimalnych kosztach płatnych zapytań API.

3. Model fizyczny hurtowni danych przygotowany w dowolnym narzędziu do projektowania (uwzględniający tabele, kolumny, typy danych, wymagalność i relacje)

DIM_CUSTOMER	
PK	SK_CUSTOMER
DD	ID_CUSTOMER
	NAME
	EMAIL
	CUSTOMER_STATE
	VALID_FROM
	VALID_TO
	IS_CURRENT
	DIST_TO_NEAREST_OWN_SITE_M
	DIST_TO_NEAREST_COMP_BAKERY_M
	DIST_TO_NEAREST_COMP_SUPERMARKET_M
	COMP_BAKERY_COUNT_300M
	COMP_BAKERY_COUNT_500M
	COMP_BAKERY_COUNT_1000M
	COMP_BAKERY_COUNT_2000M
	COMP_SUPERMARKET_COUNT_500M
	COMP_SUPERMARKET_COUNT_1000M
	COMP_SUPERMARKET_COUNT_2000M
	COMP_SUPERMARKET_COUNT_3000M
	OWN_SITE_COUNT_300M
	OWN_SITE_COUNT_500M
	OWN_SITE_COUNT_1000M
	OWN_SITE_COUNT_2000M
	OWN_SITE_COUNT_3000M

DIM_CUSTOMER_ADDRESS	
PK	SK_CUSTOMER_ADDRESS
DD	ID_CUSTOMER_ADDRESS
	ADDRESS_NAME
	ADDRESS
	LONGITUDE
	LATITUDE
	GEO_POINT
	ADDITIONAL_INFORMATION
	STATE

DIM_DELIVERY_MAN	
PK	SK_DELIVERY_MAN
DD	ID_DELIVERY_MAN
	NAME
	EMAIL
	PHONE_NUMBER
	VALID_FROM
	VALID_TO
	IS_CURRENT

DIM_DISCOUNT	
PK	SK_DISCOUNT
DD	ID_DISCOUNT
	DISCOUNT_PERCENTAGE
	DISCOUNT_FLAT_RATE
	DISCOUNT_CODE
	VALID_FROM
	VALID_TO
	IS_CURRENT
	USE_LIMIT_GLOBALLY
	USE_LIMIT_PER_USER
	MINIMAL_TRANSACTION_AMOUNT
	ONLY_FOR_FIRST_PURCHASE

DIM_PAYMENT_METHOD	
PK	SK_PAYMENT_METHOD
DD	ID_PAYMENT_METHOD
	TYPE
	CURRENCY
	CARD_BRAND
	MOBILE

FACT_CUSTOMER_CONSENT	
PK	SK_CUSTOMER_CONSENT
DD	ID_CUSTOMER_CONSENT
DD	ID_CUSTOMER
DD	ID_CONSENT
FK	SK_START_DATE
FK	SK_CUSTOMER
FK	SK_END_DATE
	IS_ACTIVE
	CONSENT_NAME

FACT_PLANNER_ITEM	
PK	SK_PLANNER_ITEM
DD	ID_PLANNER_ITEM
DD	ID_BOUGHT_OFFER_INSTANCE
DD	ID_OFFER
DD	ID_LOCATION
DD	ID_SITE
DD	ID_CUSTOMER_ADDRESS
DD	ID_CUSTOMER
FK	SK_CUSTOMER_ADDRESS
FK	SK_SITE
FK	SK_START_DATE
FK	SK_END_DATE
FK	SK_OFFER
FK	SK_LOCATION
FK	SK_CUSTOMER
	NEXT_VERSION
	PREVIOUS_VERSION
	DAY_INDEX
	QUANTITY
	PLANNER_ITEM_STATE
	DURATION_DAYS
	IS_ACTIVE

FACT_ORDER_ITEM	
PK	SK_ORDER_ITEM
DD	ID_ORDER_ITEM
DD	ID_ORDER
DD	ID_BOUGHT_OFFER_INSTANCE
DD	ID_CUSTOMER_ADDRESS
DD	ID_PLATFORM_DISCOUNT
DD	ID_LOCATION
DD	ID_SITE
DD	ID_OFFER
DD	ID_CUSTOMER
DD	ID_PLANNER_ITEM
FK	SK_DATE_ORDER
FK	SK_OFFER
FK	SK_CUSTOMER_ADDRESS
FK	SK_LOCATION
FK	SK_SITE
FK	SK_CUSTOMER
	PRICE
	TYPE
	ORDER_ITEM_STATE
	MODIFIED_BY_HAND
	ORDER_STATE
	QUANTITY
	VAT
	DISCOUNT_PERCENT
	WEATHER_MORNING_PRECIP_PROB
	WEATHER_MORNING_PRECIP_SUM_MM
	WEATHER_MORNING_WAS_RAINY

FACT_PAYMENT	
PK	SK_PAYMENT
DD	ID_PAYMENT
DD	ID_ORDER
DD	ID_DELIVERY
DD	ID_DISCOUNT
DD	ID_SITE
DD	ID_CUSTOMER
DD	ID_CLIENT
DD	ID_PAYMENT_METHOD
DD	ID_LOCATION
FK	SK_SITE
FK	SK_DISCOUNT
FK	SK_PAYMENT_METHOD

DIM_LOCATION	
PK	SK_LOCATION
DD	ID_LOCATION
	NAME
	DESCRIPTION
	STATUS
	VERTEXES
	VALID_FROM
	VALID_TO
	IS_CURRENT

DIM_INGREDIENT	
PK	SK_INGREDIENT
DD	ID_INGREDIENT
	NAME
	Unit

BRIDGE_PRODUCT_INGREDIENT	
PK	SK_PRODUCT_INGREDIENT
DD	ID_PRODUCT_INGREDIENT
FK	SK_PRODUCT
FK	SK_INGREDIENT
	VALUE
	IS_PUBLIC
	VALID_FROM
	VALID_TO
	IS_CURRENT

DIM_PRODUCT	
PK	SK_PRODUCT
DD	ID_PRODUCT
	NAME
	DESCRIPTION
	STATE
	PRODUCT_TYPE_NAME
	WEIGHT
	CALORIES
	TOTAL_FATS
	SATURATED_FATS
	TOTAL_CARBOHYDRATES
	SUGAR
	PROTEIN
	SODIUM
	VALID_FROM
	VALID_TO
	IS_CURRENT

BRIDGE_OFFER_PRODUCT	
PK	SK_OFFER_PRODUCT
FK	SK_OFFER
FK	SK_PRODUCT
	PRODUCT_COUNT
	PRODUCT_IN_OFFER_COUNT
	VALID_FROM
	VALID_TO
	IS_CURRENT


DIM_OFFER	
PK	SK_OFFER
DD	ID_OFFER
	NAME
	PRICE
	STATE
	TYPE
	VAT
	VALID_FROM
	VALID_TO
	IS_CURRENT

DIM_SITE	
PK	SK_SITE
DD	ID_SITE
DD	ID_CLIENT
DD	ID_COORDINATES
	CLIENT_NAME
	CLIENT_DESCRIPTION
	CLIENT_STREET
	CLIENT_CITY
	CLIENT_COUNTRY
	CLIENT_ZIPCODE
	CLIENT_EMAIL
	CLIENT_FULL_FORMAL_NAME
	CLIENT_PHONE
	NAME
	STREET

DIM_ALLERGEN	
PK	SK_ALLERGEN
DD	ID_ALLERGEN
	NAME

BRIDGE_PRODUCT_ALLERGEN	
PK	SK_PRODUCT_ALLERGEN
DD	ID_PRODUCT_ALLERGEN
FK	SK_PRODUCT
FK	SK_ALLERGEN
	VALID_FROM
	VALID_TO
	IS_CURRENT

DIM_COMPETITORS	
PK	SK_COMPETITOR
DD	ID_COMPETITOR
	CATEGORY
	NAME
	LATITUDE
	LONGITUDE
	GEO_POINT
	ADDRESS
	VALID_FROM
	VALID_TO
	IS_CURRENT



Column Types (BigQuery)

FACT_ORDER_ITEM

Kolumna	Typ w BigQuery	Uwagi
SK_ORDER_ITEM	INT64	
ID_ORDER_ITEM	INT64	
ID_ORDER	INT64	
ID_BOUGHT_OFFER_INSTANCE	INT64	
ID_CUSTOMER_ADDRESS	INT64	
ID_PLATFORM_DISCOUNT	INT64	
ID_LOCATION	INT64	
ID_SITE	INT64	
ID_OFFER	INT64	
ID_CUSTOMER	INT64	
ID_PLANNER_ITEM	INT64	
SK_DATE_ORDER	INT64	
SK_OFFER	INT64	
SK_CUSTOMER_ADDRESS	INT64	
SK_LOCATION	INT64	
SK_SITE	INT64	
SK_CUSTOMER	INT64	
PRICE	NUMERIC	
TYPE	STRING	
ORDER_ITEM_STATE	STRING	
MODIFIED_BY_HAND	BOOL	
ORDER_STATE	STRING	
QUANTITY	INT64	
VAT	NUMERIC	
DISCOUNT_PERCENT	NUMERIC	
WEATHER_MORNING_PRECIP_PROB	INT64	max prawdopodobieństwo opadu w oknie 6-10, %
WEATHER_MORNING_PRECIP_SUM_MM	NUMERIC	suma opadów w oknie 6-10, mm
WEATHER_MORNING_WAS_RAINY	BOOL	

DIM_SITE

Kolumna	Typ w BigQuery	Uwagi
SK_SITE	INT64	
ID_SITE	INT64	
ID_CLIENT	INT64	
ID_COORDINATES	INT64	
CLIENT_NAME	STRING	
CLIENT_DESCRIPTION	STRING	
CLIENT_STREET	STRING	

Kolumna	Typ w BigQuery	Uwagi
CLIENT_CITY	STRING	
CLIENT_COUNTRY	INT64	
CLIENT_ZIPCODE	STRING	
CLIENT_EMAIL	STRING	
CLIENT_FULL_FORMAL_NAME	STRING	
CLIENT_PHONE	STRING	
NAME	STRING	
STREET	STRING	
NR	STRING	
CITY	STRING	
STATE	STRING	
COUNTRY	INT64	
ZIPCODE	STRING	
LATITUDE	FLOAT64	
LONGITUDE	FLOAT64	
GEO_POINT	GEOGRAPHY	
VALID_FROM	TIMESTAMP	
VALID_TO	TIMESTAMP	
IS_CURRENT	BOOL	

DIM_LOCATION

Kolumna	Typ w BigQuery	Uwagi
SK_LOCATION	INT64	
ID_LOCATION	INT64	
NAME	STRING	
DESCRIPTION	STRING	
STATUS	STRING	
VERTEXES	STRING	
VALID_FROM	TIMESTAMP	
VALID_TO	TIMESTAMP	
IS_CURRENT	BOOL	

DIM_CUSTOMER_ADDRESS

Kolumna	Typ w BigQuery	Uwagi
SK_CUSTOMER_ADDRESS	INT64	
ID_CUSTOMER_ADDRESS	INT64	
ADDRESS_NAME	STRING	
ADDRESS	STRING	

Kolumna	Typ w BigQuery	Uwagi
LONGITUDE	FLOAT64	
LATITUDE	FLOAT64	
GEO_POINT	GEOGRAPHY	
ADDITIONAL_INFORMATION	STRING	
STATE	STRING	

DIM_CUSTOMER

Kolumna	Typ w BigQuery	Uwagi
SK_CUSTOMER	INT64	
ID_CUSTOMER	INT64	
NAME	STRING	
EMAIL	STRING	
CUSTOMER_STATE	STRING	
VALID_FROM	TIMESTAMP	
VALID_TO	TIMESTAMP	
IS_CURRENT	BOOL	
DIST_TO_NEAREST_OWN_SITE_M	FLOAT64	
DIST_TO_NEAREST_COMP_BAKERY_M	FLOAT64	
DIST_TO_NEAREST_COMP_SUPERMARKET_M	FLOAT64	
COMP_BAKERY_COUNT_300M	INT64	
COMP_BAKERY_COUNT_500M	INT64	
COMP_BAKERY_COUNT_1000M	INT64	
COMP_BAKERY_COUNT_2000M	INT64	
COMP_SUPERMARKET_COUNT_500M	INT64	
COMP_SUPERMARKET_COUNT_1000M	INT64	
COMP_SUPERMARKET_COUNT_2000M	INT64	
COMP_SUPERMARKET_COUNT_3000M	INT64	
OWN_SITE_COUNT_300M	INT64	
OWN_SITE_COUNT_500M	INT64	
OWN_SITE_COUNT_1000M	INT64	
OWN_SITE_COUNT_2000M	INT64	
OWN_SITE_COUNT_3000M	INT64	

FACT_DELIVERY_ITEM

Kolumna	Typ w BigQuery	Uwagi
SK_DELIVERY_ITEM	INT64	
ID_DELIVERY_ITEM	INT64	
ID_CUSTOMER_ADDRESS	INT64	

Kolumna	Typ w BigQuery	Uwagi
ID_DELIVERY_MAN	INT64	
ID_PRODUCT	INT64	
ID_DELIVERY	INT64	
ID_SITE	INT64	
ID_CUSTOMER	INT64	
ID_LOCATION	INT64	
ID_ORDER	INT64	
SK_LOCATION	INT64	
SK_CUSTOMER	INT64	
SK_DELIVERY_MAN	INT64	
SK_SITE	INT64	
SK_CUSTOMER_ADDRESS	INT64	
SK_PRODUCT	INT64	
SK_DATE_DELIVERY	INT64	
PLANNED_QUANTITY	INT64	
PACKED_QUANTITY	INT64	
PRODUCT_PRICE	NUMERIC	

DIM_DELIVERY_MAN

Kolumna	Typ w BigQuery	Uwagi
SK_DELIVERY_MAN	INT64	
ID_DELIVERY_MAN	INT64	
NAME	STRING	
EMAIL	STRING	
PHONE_NUMBER	STRING	
VALID_FROM	TIMESTAMP	
VALID_TO	TIMESTAMP	
IS_CURRENT	BOOL	

FACT_CLAIM_ITEM

Kolumna	Typ w BigQuery	Uwagi
SK_CLAIM_ITEM	INT64	
ID_CLAIM_ITEM	INT64	
ID_CLAIM	INT64	
ID_ORDER	INT64	
ID_DELIVERY	INT64	
ID_SITE	INT64	
ID_PRODUCT	INT64	

Kolumna	Typ w BigQuery	Uwagi
ID_CUSTOMER	INT64	
ID_LOCATION	INT64	
SK_DATE_CLAIM	INT64	
SK_PRODUCT	INT64	
SK_CUSTOMER	INT64	
SK_SITE	INT64	
SK_LOCATION	INT64	
STATE	STRING	
TYPE	STRING	
ID_AGREED_DISCOUNT	INT64	
AGREED_RETURN_AMOUNT	NUMERIC	
DESCRIPTION	STRING	
ORDERED_QUANTITY	INT64	
DELIVERED_QUANTITY	INT64	
NUMBER_OF_PRODUCTS_WITH_ACCEPTED_CLAIM	INT64	
CLAIMED_QUANTITY	INT64	
ISSUE_TYPE	STRING	

FACT_PAYMENT

Kolumna	Typ w BigQuery	Uwagi
SK_PAYMENT	INT64	
ID_PAYMENT	INT64	
ID_ORDER	INT64	
ID_DELIVERY	INT64	
ID_DISCOUNT	INT64	
ID_SITE	INT64	
ID_CUSTOMER	INT64	
ID_CLIENT	INT64	
ID_PAYMENT_METHOD	INT64	
ID_LOCATION	INT64	
SK_SITE	INT64	
SK_DISCOUNT	INT64	
SK_PAYMENT_METHOD	INT64	
SK_CUSTOMER	INT64	
SK_DATE_PAYMENT	INT64	
SK_LOCATION	INT64	
AMOUNT	NUMERIC	
LIST_OF_ORDER_ITEMS	STRING	
ERROR	STRING	

DIM_PAYMENT_METHOD

Kolumna	Typ w BigQuery	Uwagi
SK_PAYMENT_METHOD	INT64	
ID_PAYMENT_METHOD	INT64	
TYPE	STRING	
CURRENCY	STRING	
CARD_BRAND	STRING	
MOBILE	BOOL	

FACT_CUSTOMER_CONSENT

Kolumna	Typ w BigQuery	Uwagi
SK_CUSTOMER_CONSENT	INT64	
ID_CUSTOMER_CONSENT	INT64	
ID_CUSTOMER	INT64	
ID_CONSENT	INT64	
SK_START_DATE	INT64	
SK_CUSTOMER	INT64	
SK_END_DATE	INT64	
IS_ACTIVE	BOOL	
CONSENT_NAME	STRING	

FACT_PLANNER_ITEM

Kolumna	Typ w BigQuery	Uwagi
SK_PLANNER_ITEM	INT64	
ID_PLANNER_ITEM	INT64	
ID_BOUGHT_OFFER_INSTANCE	INT64	
ID_OFFER	INT64	
ID_LOCATION	INT64	
ID_SITE	INT64	
ID_CUSTOMER_ADDRESS	INT64	
ID_CUSTOMER	INT64	
SK_CUSTOMER_ADDRESS	INT64	
SK_SITE	INT64	
SK_START_DATE	INT64	
SK_END_DATE	INT64	
SK_OFFER	INT64	
SK_LOCATION	INT64	
SK_CUSTOMER	INT64	

Kolumna	Typ w BigQuery	Uwagi
NEXT_VERSION	STRING	
PREVIOUS_VERSION	STRING	
DAY_INDEX	INT64	
QUANTITY	INT64	
PLANNER_ITEM_STATE	STRING	
DURATION_DAYS	INT64	
IS_ACTIVE	BOOL	

DIM_DISCOUNT

Kolumna	Typ w BigQuery	Uwagi
SK_DISCOUNT	INT64	
ID_DISCOUNT	INT64	
DISCOUNT_PERCENTAGE	NUMERIC	
DISCOUNT_FLAT_RATE	NUMERIC	
DISCOUNT_CODE	NUMERIC	
VALID_FROM	TIMESTAMP	
VALID_TO	TIMESTAMP	
IS_CURRENT	BOOL	
USE_LIMIT_GLOBALLY	BOOL	
USE_LIMIT_PER_USER	BOOL	
MINIMAL_TRANSACTION_AMOUNT	NUMERIC	
ONLY_FOR_FIRST_PURCHASE	BOOL	

DIM_PRODUCT

Kolumna	Typ w BigQuery	Uwagi
SK_PRODUCT	INT64	
ID_PRODUCT	INT64	
NAME	STRING	
DESCRIPTION	STRING	
STATE	STRING	
PRODUCT_TYPE_NAME	STRING	
WEIGHT	FLOAT64	
CALORIES	FLOAT64	
TOTAL_FATS	FLOAT64	
SATURATED_FATS	FLOAT64	
TOTAL_CARBOHYDRATES	FLOAT64	
SUGAR	FLOAT64	
PROTEIN	FLOAT64	

Kolumna	Typ w BigQuery	Uwagi
SODIUM	FLOAT64	
VALID_FROM	TIMESTAMP	
VALID_TO	TIMESTAMP	
IS_CURRENT	BOOL	

FACT_REFUND_ITEM

Kolumna	Typ w BigQuery	Uwagi
SK_REFUND_ITEM	INT64	
ID_REFUND_ITEM	INT64	
ID_REFUND	INT64	
ID_PRODUCT	INT64	
ID_CLAIM	INT64	
ID_PAYMENT	INT64	
ID_SITE	INT64	
ID_CUSTOMER	INT64	
ID_CLIENT	INT64	
ID_LOCATION	INT64	
SK_DATE_REFUND	INT64	
SK_SITE	INT64	
SK_PRODUCT	INT64	
SK_CUSTOMER	INT64	
SK_LOCATION	INT64	
MISSING_PRODUCT_QUANTITY	INT64	
AMOUNT	NUMERIC	
VAT_AMOUNT	NUMERIC	

DIM_OFFER

Kolumna	Typ w BigQuery	Uwagi
SK_OFFER	INT64	
ID_OFFER	INT64	
NAME	STRING	
PRICE	NUMERIC	
STATE	STRING	
TYPE	STRING	
VAT	NUMERIC	
VALID_FROM	TIMESTAMP	
VALID_TO	TIMESTAMP	
IS_CURRENT	BOOL	

BRIDGE_OFFER_PRODUCT

Kolumna	Typ w BigQuery	Uwagi
SK_OFFER_PRODUCT	INT64	
SK_OFFER	INT64	
SK_PRODUCT	INT64	
PRODUCT_COUNT	INT64	
PRODUCT_IN_OFFER_COUNT	INT64	
VALID_FROM	TIMESTAMP	
VALID_TO	TIMESTAMP	
IS_CURRENT	BOOL	

DIM_DATE

Kolumna	Typ w BigQuery	Uwagi
SK_DATE	INT64	
MONTH_NAME	STRING	
WEEKDAY_NAME	STRING	
IS_WORKING	BOOL	
IS_HOLIDAY	BOOL	
IS_WEEKEND	BOOL	
WEEKDAY_NUMBER	INT64	
MONTH_NUMBER	INT64	
YEAR	INT64	
QUARTER	INT64	

DIM_INGREDIENT

Kolumna	Typ w BigQuery	Uwagi
SK_INGREDIENT	INT64	
ID_INGREDIENT	INT64	
NAME	STRING	
Unit	STRING	

BRIDGE_PRODUCT_INGREDIENT

Kolumna	Typ w BigQuery	Uwagi
SK_PRODUCT_INGREDIENT	INT64	
ID_PRODUCT_INGREDIENT	INT64	
SK_PRODUCT	INT64	
SK_INGREDIENT	INT64	

Kolumna	Typ w BigQuery	Uwagi
VALUE	FLOAT64	
IS_PUBLIC	BOOL	
VALID_FROM	TIMESTAMP	
VALID_TO	TIMESTAMP	
IS_CURRENT	BOOL	

DIM_ALLERGEN

Kolumna	Typ w BigQuery	Uwagi
SK_ALLERGEN	INT64	
ID_ALLERGEN	INT64	
NAME	STRING	

BRIDGE_PRODUCT_ALLERGEN

Kolumna	Typ w BigQuery	Uwagi
SK_PRODUCT_ALLERGEN	INT64	
ID_PRODUCT_ALLERGEN	INT64	
SK_PRODUCT	INT64	
SK_ALLERGEN	INT64	
VALID_FROM	TIMESTAMP	
VALID_TO	TIMESTAMP	
IS_CURRENT	BOOL	

DIM_COMPETITORS

Kolumna	Typ w BigQuery	Uwagi
SK_COMPETITOR	INT64	
ID_COMPETITOR	INT64	
CATEGORY	STRING	
NAME	STRING	
LATITUDE	FLOAT64	
LONGITUDE	FLOAT64	
GEO_POINT	GEOGRAPHY	
ADDRESS	STRING	
VALID_FROM	TIMESTAMP	
VALID_TO	TIMESTAMP	
IS_CURRENT	BOOL	

4. Opis kluczowych miar i atrybutów w modelu

4.1 Measures and Aggregation Methods

FACT_ORDER_ITEM

Measure	Business Description	Default Aggregation
PRICE	Value/Price for a given product/offer	SUM (Revenue), AVG (Average price)
QUANTITY	Quantity of ordered items	SUM
VAT	VAT tax amount	SUM
DISCOUNT_PERCENT	Applied discount in percentage	AVG, MAX
WEATHER_MORNING_WAS_RAINY	(PRECIP_PROB >= 50 AND PRECIP_SUM_MM >= 1.0) OR (PRECIP_SUM_MM >= 2.5)	CUSTOM

FACT_DELIVERY_ITEM

Measure	Business Description	Default Aggregation
PLANNED_QUANTITY	Quantity planned for delivery	SUM
PACKED_QUANTITY	Quantity actually packed	SUM
PRODUCT_PRICE	Value of the product in delivery	SUM

FACT_CLAIM_ITEM

Measure	Business Description	Default Aggregation
AGREED_RETURN_AMOUNT	Agreed return amount for the customer	SUM
ORDERED_QUANTITY	Initially ordered quantity (context)	SUM, MAX
DELIVERED_QUANTITY	Actually delivered quantity (context)	SUM, MAX
NUMBER_OF_PRODUCTS_WITH_ACCEPTED_CLAIM	Number of accepted products in the claim	SUM
CLAIMED_QUANTITY	Quantity reported in the claim	SUM

FACT_PAYMENT & FACT_REFUND_ITEM

Measure	Business Description	Default Aggregation
AMOUNT (PAYMENT)	Booked payment amount	SUM
AMOUNT (REFUND)	Actual refund amount (net/gross)	SUM
VAT_AMOUNT	Refunded VAT amount	SUM
MISSING_PRODUCT_QUANTITY	Quantity of missing products forming the basis of the refund	SUM

FACT_PLANNER_ITEM

Measure	Business Description	Default Aggregation
QUANTITY	Number of items in the subscription plan	SUM
DURATION_DAYS	Duration of the plan / cycle	AVG, MAX

4.2 Key Attributes

Spatial and Logistics Attributes (GIS)

Tables: DIM_SITE , DIM_CUSTOMER_ADDRESS , DIM_COMPETITORS

- **Categorizing:** CITY , ZIPCODE , STATE , COUNTRY , STREET .
- **GIS (Coordinates):** LATITUDE , LONGITUDE , GEO_POINT .
- **Reach Indicators in DIM_CUSTOMER :**
 - DIST_TO_NEAREST_OWN_SITE_M , DIST_TO_NEAREST_COMP_BAKERY_M
 - COMP_BAKERY_COUNT_500M , OWN_SITE_COUNT_1000M

Product and Marketing Attributes

Tables: DIM_PRODUCT , DIM_OFFER , DIM_DISCOUNT , DIM_INGREDIENT

- **Categorizing:** PRODUCT_TYPE_NAME , TYPE (in offer), CATEGORY (Competitors).
- **Technical/Nutritional:** CALORIES , TOTAL_FATS , SUGAR .
- **Promotional:** DISCOUNT_CODE , ONLY_FOR_FIRST_PURCHASE .

Status Attributes

- **In orders:** ORDER_ITEM_STATE , ORDER_STATE , MODIFIED_BY_HAND .
- **In payments:** TYPE , CARD_BRAND , MOBILE .
- **In claims:** STATE , ISSUE_TYPE .

4.3 Analytical Hierarchies

A. Time Hierarchy (DIM_DATE)

1. YEAR
2. QUARTER
3. MONTH_NAME / MONTH_NUMBER
4. WEEKDAY_NAME / WEEKDAY_NUMBER
5. SK_DATE

B. Geographical Hierarchy

1. COUNTRY
2. STATE
3. CITY
4. ZIPCODE
5. STREET / ADDRESS

C. Operational-Management Hierarchy

1. DIM_LOCATION
2. DIM_SITE

(Note: DIM_DELIVERY_MAN and DIM_CUSTOMER are independent dimensions. They are linked to a specific site dynamically per transaction via Fact tables, because a customer can order from multiple sites.)

D. Product-Offer Hierarchy

1. DIM_OFFER
2. DIM_PRODUCT
3. DIM_INGREDIENT / DIM_ALLERGEN

(Note: These relationships are Many-to-Many (N:M) resolved via Bridge tables like BRIDGE_OFFER_PRODUCT, meaning a single product can belong to multiple offers, and an ingredient to multiple products.)

5. Opis planowanych raportów dla użytkowników

Podczas rozmowy z klientem o jego potrzebach doszliśmy do wniosku, że klient jest zainteresowany informacjami o rentowności obszarów, oraz o częstotliwościach zakupów przez klientów. Natomiast niestety klient zidentyfikował zdefiniowanie rentowności jako problematyczne. Dlatego skorzystamy z prostszych rozwiązań i będziemy mierzyć rentowność wartościami zamówień.

5.1 Raport pokazujący wpływ pogody na wartość zamówień

Dlaczego? Chcemy sprawdzić czy aktualna forma dostawy nie stanowi bariery zniechęcającej do zakupu.

Jak?

Pokażemy wykresy porównujące średnie przychody w deszczowe oraz nieszczęśliwe dni w kolejnych miesiącach. Słupkowy wykres prognozowanej ilości opadów, z naniesionym wykresem punktowym połączonym linią wartości zamówień z oznaczeniem dni deszczowych. Wykres w ujęciu miesięcznym.

5.2 Raport pokazujący wpływ ilości piekarni w okolicy na wartość zamówień

Dlaczego? Chcemy sprawdzić jak dużą konkurencją są stacjonarne piekarnie.

Jak?

Jest to dosyć trudne zadanie ponieważ dane mogą być skorelowane ale nie być ze sobą związane, np. licząc po łącznej wartości zamówień i odległości od piekarni może nam wyjść korelacja ale może ona być związana z tym, że na obrzeżach miasta mieszka mniej ludzi więc jest mniej piekarni oraz mniej wartości. Natomiast nie ma tutaj zbyt dobrego wyjścia bo ciężko zmierzyć brak zamówień jakimikolwiek średnimi, więc mimo wszystko założymy jednostajną gęstość zaludnienia, co jest rozsądnym założeniem bo klient zaplanował obszary tak, żeby nie dowozić na odludzia.

Dlatego pokażemy heat mapę sumy wartości zamówień w podziale na buckety, to jest w pierwszej kolumnie będziemy mieli COMP_BAKERY_COUNT_300M dla n = 1, 2, 3-4, 5+, w drugiej COMP_BAKERY_COUNT_500M dla tych samych n w trzeciej COMP_BAKERY_COUNT_1000M oraz czwartej COMP_BAKERY_COUNT_2000M. Dane powinny nieść uniwersalną informację niezależną od czasu i miejsca, więc w miarę napływu danych będziemy ją zawsze obliczać dla wszystkich danych.

5.3 Raport pokazujący wpływ ilości supermarketów w okolicy na wartość zamówień

Dlaczego? Chcemy sprawdzić jak dużą konkurencją są supermarkety.

Jak?

Analogicznie do raportu wpływu ilości piekarni ale używając kolumn COMP_SUPERMARKET_COUNT_500M, COMP_SUPERMARKET_COUNT_1000M, COMP_SUPERMARKET_COUNT_2000M oraz COMP_SUPERMARKET_COUNT_3000M jako buckety w kolumnach heat mapy.

5.4 Raport pokazujący charakteryzujący regularnych klientów

Dlaczego? Chcemy sprawdzić kto jest naszym klientem, oraz czy warto skupić się w 100% na klientach regularnych zaniedbując okazjonalnych.

Jak?

Pokażemy histogram ilu jest klientów którzy zamawiają w n-dni w tygodniu (7 słupków) oraz histogram wartości zamówień z każdej grupy, dla różnych miesięcy. Dwa histogramy co miesiąc.