

0. Dashboardy z naszej hurtowni

Dashboardy z naszej hurtowni można obejrzeć pod poniższym linkiem:

<https://datastudio.google.com/reporting/46e778d6-111d-4d84-b31a-bccd57b78bea>

1. Rozszerzony opis wykorzystywanych zbiorów danych

Dane o punktach POI (Google Maps API) Dane o konkurencji i punktach użyteczności publicznej pozyskujemy z Google Maps API (New). Choć dane te są dostępne "na żądanie" w czasie rzeczywistym, nasza architektura stawia na rygorystyczną minimalizację liczby zapytań w celu optymalizacji kosztów. Wykorzystujemy zapytania zdefiniowane przestrzennie, na które nakładamy ściśle filtry kategorii (np. tylko piekarnie i supermarkety) oraz maski pól (FieldMask), dzięki czemu pobieramy wyłącznie niezbędne atrybuty (nazwa, adres, współrzędne GPS). Należy mieć na uwadze ograniczenie samego API, które dla zapytania przestrzennego zwraca maksymalnie 20 wyników.

Dane pogodowe, dane odnośnie deszczu (open-meteo.com) Podczas rozmów z klientem, dotarliśmy do informacji, że proces sprzedażowy wykorzystuje mechanizm zawieszania zamówienia na płocie bądź pozostawienie go w innej formie na zewnątrz przed domem zamawiającego. W związku z powyższym podjęliśmy decyzję biznesową aby nasza hurtownia umożliwiała zestawienie danych sprzedażowych z opadami w godzinach dostarczania zamówień.

Na początku myśleliśmy o uwzględnieniu historycznych zapisów pogodowych dla konkretnych współrzędnych, natomiast po analizie doszliśmy do wniosku, że dużo lepszym predyktorem wpływu pogody na sprzedaż jest nie to jaka faktycznie była pogoda, ale jaka miała być pogoda. Dzięki temu uwzględniamy lepiej to czym się kierowała np. dzień wcześniej większość zamawiających klientów. Dlatego pobierając dane pobieramy informacje na temat prognoz w godzinach 6-10 rano. Zbieramy takie dane jak maksymalne prawdopodobieństwo opadów w tych godzinach, oraz sumę opadów z tych godzin w milimetrach.

2. Opis planowanego procesu ELT ze szczególnym uwzględnieniem sposobu transformacji i integracji danych

2.1 Faza Ekstrakcji

Ekstrakcja następuje z trzech źródeł: baza bake2home, google maps api, oraz open-meteo.

Najpierw sprawdzamy datę ostatniego eksportu i eksportujemy nowe rekordy z każdej tabeli z każdej bazy jako osobne csv.

Zauważmy, że dane z open-meteo oraz google maps api są ściśle powiązane z szerokością i długością geograficzną danych z bake2home. Dlatego w celu optymalnego wykorzystania api najpierw musimy wyeksportować w csv wynik zapytania do bazy bake2home, gdzie prosimy o wszystkie nowe szerokości i długości geograficzne oraz daty, tak żeby wiedzieć dla jakich parametrów ściągać dane z google maps api, oraz open meteo do późniejszej fazy transformacji. Aby to zrobić należy z bazy delivery-manager-db, z tabeli Deliveries należy wziąć int OrderId, i zrobić joina po OrderId z tabelą Bakery Orders z bazy planner-db, tak aby mieć listę deliveries z Date, oraz Latitude oraz Longitude odpowiadającą danym z tabeli

FactOrderItem. Następnie na podstawie listy Latitude i Longitude ściągnąć dane z Google Maps API z współrzędnymi wszystkich punktów w okolicy oraz zapisać do pliku CSV:

Kategoria	Nazwa	Adres	Szerokość (Lat)	Długość (Lon)	Typy Google
Piekarnia/Cukiernia	Kołacz na Okrągło Auchan Okęcie	Aleja Krakowska 61, 02-285 Warszawa	52.1711992	20.9346711	bakery, food_store, food, point_of_interest, store, establishment
Supermarket	Biedronka	Sportowa 1, 05-090 Raszyn	52.1536184	20.9217322	discount_supermarket, supermarket, grocery_store, food_store, food, store, establishment
Supermarket	Delikatesy Centrum	Pruszkowska 52, 05-090 Raszyn	52.1612933	20.9147626	grocery_store, supermarket, deli, food_store, food, store, point_of_interest, establishment

Jezeli chodzi o dane z open-meteo to zdecydowaliśmy się na ustawianie ich domyślnie na -1 -ki a następnie codziennie o północy przy użyciu Cloud Schedulera oraz Cloud run functions doładowywać brakujące dane w sposób automatyczny. Skrypt dla każdego zamówienia doładowuje pogodę.

2.2 Faza Ładowania (Big Query)

Wrzucamy wszystkie pliki .csv do bucketu Google Cloud Storage, a następnie tworzymy tabele w bigquery odpowiadające wyeksportowanym wcześniej plikom .csv, oraz dwóm plikom z danymi z google maps, oraz z danymi opadowymi. Finalnie tabele uzupełniamy uploadem .csv z GCS.

2.3 Proces ELT – Faza Transformacji (Google Cloud Dataform)

Transformacja danych surowych w docelowy model wielowymiarowy (Star Schema) odbywa się bezpośrednio w silniku BigQuery za pomocą narzędzia Google Cloud Dataform. Proces obejmuje trzy kluczowe operacje:

Generowanie Kluczy Zastępczych (Surrogate Keys): Dataform generuje unikalne klucze SK_ (typu INT64) dla każdego rekordu wymiaru, wykorzystując natywne funkcje hashujące BigQuery (np. FARM_FINGERPRINT). Uniezależnia to hurtownię od zmian identyfikatorów w systemach źródłowych i zapewnia integralność referencyjną między faktami a wymiarami.

Implementacja Historyzacji (SCD2): Dataform automatycznie zarządza wymiarami wolnozmiennymi Typu 2. W przypadku wykrycia zmiany w atrybutach wymiaru (np. zmiana adresu klienta), stary rekord zostaje "wygaszony" (aktualizacja IS_CURRENT i VALID_TO), a nowy wstawiany z aktualną datą VALID_FROM. Gwarantuje to pełną spójność danych historycznych bez konieczności pisania skomplikowanych zapytań MERGE.

Integracja Wieloźródłowa (Cross-Source Joins & Spatial Analytics): Wewnętrzne dane operacyjne (np. adresy klientów z bazy Bake2Home) są łączone za pomocą Spatial Joinów z zewnętrznymi danymi z Google Maps API (tabela DIM_COMPETITORS). Wykorzystując funkcje GIS (np. ST_DISTANCE), Dataform przelicza zdenormalizowane metryki odległościowe, które trafiają bezpośrednio jako atrybuty analityczne do tabeli DIM_CUSTOMER. Dzięki danym z meteo API dataform przelicza również informację czy zamówienie było dostarczane w deszczowy dzień, informacja ta trafia do tabeli FACT_ORDER_ITEM.

Harmonogram Odświeżania Danych (Data Refresh Strategy)

Procesy ładujące i transformujące są orkiestrowane z różną częstotliwością, aby zapewnić optymalny balans między świeżością danych a kosztami operacyjnymi:

Dane operacyjne (Bake2Home DB): Codziennie w nocy (Daily Nightly Batch). Klasyczny widok "T-1" na wczorajsze zamknięcie dnia, bez obciążania systemów produkcyjnych w godzinach szczytu.

Dane pogodowe: Codziennie około północy. Pobieramy prognozę D-1 - czyli to, co modele pogodowe prognozowały wczoraj na dzisiaj (Previous Runs API, parametr previous_model_run=1). Interesuje nas okno godzinowe 6:00–10:00 dla każdej lokalizacji dostawy.

Dane o konkurencji i POI (Google Maps API): Raz w miesiącu (Monthly). Cykl otwierania i zamykania fizycznych punktów sprzedaży charakteryzuje się niską dynamiką. Miesięczne odświeżanie gwarantuje miarodajny obraz otoczenia rynkowego przy minimalnych kosztach płatnych zapytań API.

3. Model fizyczny hurtowni danych przygotowany w dowolnym narzędziu do projektowania (uwzględniający tabele, kolumny, typy danych, wymagalność i relacje)



4. Opis kluczowych miar i atrybutów w modelu

4.1 Measures and Aggregation Methods

FACT_ORDER_ITEM

Measure	Business Description	Default Aggregation
PRICE	Value/Price for a given product/offer	SUM (Revenue), AVG (Average price)
QUANTITY	Quantity of ordered items	SUM
VAT	VAT tax amount	SUM
DISCOUNT_PERCENT	Applied discount in percentage	AVG, MAX
WEATHER_MORNING_WAS_RAINY	(PRECIP_PROB >= 50 AND PRECIP_SUM_MM >= 1.0) OR (PRECIP_SUM_MM >= 2.5)	CUSTOM

FACT_DELIVERY_ITEM

Measure	Business Description	Default Aggregation
PLANNED_QUANTITY	Quantity planned for delivery	SUM
PACKED_QUANTITY	Quantity actually packed	SUM
PRODUCT_PRICE	Value of the product in delivery	SUM

FACT_CLAIM_ITEM

Zrezygnowaliśmy z implementacji tej faktówki! :(

FACT_PAYMENT & FACT_REFUND_ITEM

Measure	Business Description	Default Aggregation
AMOUNT (PAYMENT)	Booked payment amount	SUM
AMOUNT (REFUND)	Actual refund amount (net/gross)	SUM
VAT_AMOUNT	Refunded VAT amount	SUM
MISSING_PRODUCT_QUANTITY	Quantity of missing products forming the basis of the refund	SUM

FACT_PLANNER_ITEM

Measure	Business Description	Default Aggregation
QUANTITY	Number of items in the subscription plan	SUM
DURATION_DAYS	Duration of the plan / cycle	AVG, MAX

4.2 Key Attributes

Spatial and Logistics Attributes (GIS)

Tables: DIM_SITE , DIM_CUSTOMER_ADDRESS , DIM_COMPETITORS

- **Categorizing:** CITY , ZIPCODE , STATE , COUNTRY , STREET .
- **GIS (Coordinates):** LATITUDE , LONGITUDE , GEO_POINT .
- **Reach Indicators in DIM_CUSTOMER :**
 - DIST_TO_NEAREST_OWN_SITE_M , DIST_TO_NEAREST_COMP_BAKERY_M
 - COMP_BAKERY_COUNT_500M , OWN_SITE_COUNT_1000M

Product and Marketing Attributes

Tables: DIM_PRODUCT , DIM_OFFER , DIM_DISCOUNT , DIM_INGREDIENT

- **Categorizing:** PRODUCT_TYPE_NAME , TYPE (in offer), CATEGORY (Competitors).
- **Technical/Nutritional:** CALORIES , TOTAL_FATS , SUGAR .
- **Promotional:** DISCOUNT_CODE , ONLY_FOR_FIRST_PURCHASE .

Status Attributes

- **In orders:** ORDER_ITEM_STATE , ORDER_STATE , MODIFIED_BY_HAND .
 - **In payments:** TYPE , CARD_BRAND , MOBILE .
 - **In claims:** STATE , ISSUE_TYPE .
-

4.3 Analytical Hierarchies

A. Time Hierarchy (DIM_DATE)

1. YEAR
2. QUARTER
3. MONTH_NAME / MONTH_NUMBER
4. WEEKDAY_NAME / WEEKDAY_NUMBER
5. SK_DATE

B. Geographical Hierarchy

1. COUNTRY
2. STATE
3. CITY
4. ZIPCODE
5. STREET / ADDRESS

C. Operational-Management Hierarchy

1. DIM_LOCATION
2. DIM_SITE

(Note: DIM_DELIVERY_MAN and DIM_CUSTOMER are independent dimensions. They are linked to a specific site dynamically per transaction via Fact tables, because a customer can order from multiple sites.)

D. Product-Offer Hierarchy

1. DIM_OFFER
2. DIM_PRODUCT
3. DIM_INGREDIENT / DIM_ALLERGEN

(Note: These relationships are Many-to-Many (N:M) resolved via Bridge tables like BRIDGE_OFFER_PRODUCT , meaning a single product can belong to multiple offers, and an ingredient to multiple products.)

5. Opis planowanych raportów dla użytkowników

Podczas rozmowy z klientem o jego potrzebach doszliśmy do wniosku, że klient jest zainteresowany informacjami o rentowności obszarów, oraz o częstotliwościach zakupów przez klientów. Natomiast niestety klient zidentyfikował zdefiniowanie rentowności jako problematyczne. Dlatego skorzystamy z prostszych rozwiązań i będziemy mierzyć rentowność wartościami zamówień.

5.1 Raport pokazujący wpływ pogody na wartość zamówień

Dlaczego? Chcemy sprawdzić czy aktualna forma dostawy nie stanowi bariery zniechęcającej do zakupu. Jak?

Pokażemy wykres porównujący średnie przychody w deszczowe oraz niedeszczowe dni w kolejnych miesiącach, oraz dwa wykresy punktowe: wykres prognozowanej ilości opadów, oraz wykres punktowy połączonym linią wartości zamówień. Wykres z możliwością regulacji daty.

5.2 Raport pokazujący wpływ ilości piekarni w okolicy na wartość zamówień

Dlaczego? Chcemy sprawdzić jak dużą konkurencją są stacjonarne piekarnie. Jak?

Jest to dosyć trudne zadanie ponieważ dane mogą być skorelowane ale nie być ze sobą związane, np. licząc po łącznej wartości zamówień i odległości od piekarni może nam wyjść korelacja ale może ona być związana z tym, że na obrzeżach mieszka mniej ludzi więc jest mniej piekarni oraz mniej wartości. Natomiast nie ma tutaj zbyt dobrego wyjścia bo ciężko zmierzyć brak zamówień jakimikolwiek średnimi, więc mimo wszystko założymy jednostajną gęstość zaludnienia, co jest rozsądnym założeniem bo klient zaplanował obszary tak, żeby nie dowozić na odludzia.

Dlatego pokażemy heat mapę sumy wartości zamówień w podziale na buckety, to jest w pierwszej kolumnie będziemy mieli `COMP_BAKERY_COUNT_300M` dla $n = 1, 2, 3-4, 5+$, w drugiej `COMP_BAKERY_COUNT_500M` dla tych samych n w trzeciej `COMP_BAKERY_COUNT_1000M` oraz czwartej `COMP_BAKERY_COUNT_2000M`. Dane powinny nieść uniwersalną informację niezależną od czasu i miejsca, więc w miarę napływu danych będziemy ją zawsze obliczać dla wszystkich danych.

5.3 Raport pokazujący wpływ ilości supermarketów w okolicy na wartość zamówień

Dlaczego? Chcemy sprawdzić jak dużą konkurencją są supermarkety. Jak?

Analogicznie do raportu wpływu ilości piekarni ale używając kolumn `COMP_SUPERMARKET_COUNT_500M`, `COMP_SUPERMARKET_COUNT_1000M`, `COMP_SUPERMARKET_COUNT_2000M` oraz `COMP_SUPERMARKET_COUNT_3000M` jako buckety w kolumnach heat mapy.

5.4 Raport pokazujący charakteryzujący regularnych klientów

Dlaczego? Chcemy sprawdzić kto jest naszym klientem, oraz czy warto skupić się w 100% na klientach regularnych zaniedbując okazjonalnych.

Jak?

Pokażemy histogram wartości zamówień z każdej grupy klientów którzy zamawiają w n -dni w tygodniu (7 słupków, o tym jakiego rodzaju jest klient decyduje mediana z liczby dni w których klient zamawiał w tygodniach w których zamawiał). Wykres z możliwością regulacji daty.

6. Analiza jakości i spójności danych

6.1 Raport Kompletności Danych

- **Cel:** Sprawdzenie jakości danych w systemach źródłowych i wykrycie ewentualnych anomalii w postaci braku wartości w kluczowych polach.
- **Kroki:** Uruchomienie skryptu w Jupyter Notebook łączącego się z `INFORMATION_SCHEMA` BigQuery. Skrypt iteruje po każdej tabeli we wszystkich warstwach (Bronze, Silver, Gold) i zlicza procentowy udział wartości NULL w poszczególnych kolumnach.
- **Oczekiwany wynik:** Otrzymanie czytelnego raportu w formie tabeli pokazującego odsetek braków dla każdej kolumny. Spodziewamy się wysokiej kompletności dla kluczy głównych oraz ewentualnych uzasadnionych biznesowo braków (np. data rozwiązania umowy).
- **Potwierdzenie:**

NULL DATA REPORT - LAYER: BRONZE

	table_name	row_count	column_name	null_count	null_percentage
0	raw_planner_BakeryOrders	5743	PlatformDiscountId	5743	100.00
1	raw_wallet_PaymentMethods	187	CardBrand	187	100.00
2	raw_wallet_RefundCreationErrors	122	StatusCode	122	100.00
3	raw_wallet_RefundCreationErrors	122	CodeLiteral	122	100.00
4	raw_catalog_ProductAttribute	3	BakeryProductId	3	100.00
5	raw_customer_manager_Consents	3	ExpiryDate	3	100.00
6	raw_wallet_Payments	2235	Error	2234	99.96
7	raw_wallet_Refunds	1063	ClaimId	1059	99.62
8	raw_wallet_Payments	2235	DiscountedAmount	2168	97.00
9	raw_wallet_Payments	2235	DiscountId	2167	96.96
10	raw_wallet_Discounts	21	CustomerId	19	90.48
11	raw_delivery_manager_DeliveryItems	1741	PackedQuantity	1552	89.14
12	raw_catalog_BakeryOffer	145	NextVersionId	121	83.45
13	raw_delivery_account_manager_Address	6	Voivodeship	5	83.33
14	raw_delivery_account_manager_Address	6	District	5	83.33

NULL DATA REPORT - LAYER: SILVER

	table_name	row_count	column_name	null_count	null_percentage
0	stg_payment	2235	error	2234	99.96
1	stg_payment	2235	discounted_amount	2168	97.00
2	stg_payment	2235	id_discount	2167	96.96
3	stg_discount	21	id_customer	19	90.48
4	stg_delivery_items	1741	packed_quantity	1552	89.14
5	stg_bakery_offer	145	next_version_id	121	83.45
6	stg_payment	2235	id_client	1681	75.21
7	stg_refund	1063	base_amount	767	72.15
8	stg_bakery_offer	145	previous_version_offer_id	78	53.79
9	stg_bakery_product	83	id_previous_version_product	41	49.40
10	stg_bakery_product	83	id_modified_version_product	41	49.40
11	stg_discount	21	id_client	10	47.62
12	stg_payment	2235	id_delivery	974	43.58
13	stg_deliveries	1162	id_delivery_man	84	7.23
14	stg_bakery_order_items	9454	id_planner_item	392	4.15

NULL DATA REPORT - LAYER: GOLD

	table_name	row_count	column_name	null_count	null_percentage
0	bridge_location_site	13	sk_location_site	0	0.0
1	bridge_location_site	13	id_location_site	0	0.0
2	bridge_location_site	13	id_location	0	0.0
3	bridge_location_site	13	id_site	0	0.0
4	bridge_offer_product	151	sk_offer_product	0	0.0
5	bridge_offer_product	151	id_offer_product	0	0.0
6	bridge_offer_product	151	id_offer	0	0.0
7	bridge_offer_product	151	id_product	0	0.0
8	bridge_offer_product	151	product_count	0	0.0
9	bridge_offer_product	151	product_in_offer_count	0	0.0
10	bridge_product_allergen	48	sk_product_allergen	0	0.0
11	bridge_product_allergen	48	id_product_allergen	0	0.0
12	bridge_product_allergen	48	id_product	0	0.0
13	bridge_product_allergen	48	id_allergen	0	0.0
14	bridge_product_ingredient	86	sk_product_ingredient	0	0.0

6.2 Audyt Spójności Ścieżek Danych

- **Cel:** Weryfikacja przepływu encji od surowego pliku na GCS (Bronze) do docelowej tabeli w hurtowni (Gold) pod kątem wycieków i duplikacji.
- **Kroki:** Skrypt zlicza liczbę wierszy dla 16 kluczowych encji kolejno w datasetach `bronze`, `silver` oraz `gold`.
- **Oczekiwany wynik:** Tabela faktów przenosi dokładnie 100% wolumenu na każdej warstwie. Tabele wymiarowe rosną o dokładnie 1 wiersz w warstwie Gold z powodu dodawania technicznego rekordu -999999 do obsługi braków. Brak jakichkolwiek iloczynów kartezjańskich.
- **Potwierdzenie:**

	Bronze	Silver	Gold
main_table			
dim_allergen	15	15	16
dim_competitor	483	483	481
dim_customer	176	176	177
dim_customer_address	544	544	545
dim_delivery_man	6	6	7
dim_discount	21	21	22
dim_location	35	35	36
dim_offer	145	145	146
dim_payment_method	187	187	188
dim_product	83	83	84
dim_site	8	8	9
fact_delivery_item	1741	1741	1741
fact_order_item	9454	9454	9454
fact_payment	2235	2235	2235
fact_planner_item	1931	1931	1931
fact_refund_item	1132	1132	1132

6.3 Raport Odrzutów Biznesowych i Relacji

- **Cel:** Wykrycie braków w integralności referencyjnej oraz zbudowanie profilu biznesowego transakcji (np. jaki odsetek koszyków nie zawiera zniżki).
- **Kroki:** Skanowanie wszystkich tabel faktów oraz tabel pomostowych w warstwie Gold w celu zliczenia wystąpień technicznego klucza zastępczego –999999 dla każdego klucza obcego.
- **Oczekiwany wynik:** Brak ukrytych sierot technicznych. Zidentyfikowanie naturalnych wyjątków biznesowych (np. płatności bez użycia zniżki) na oczekiwanym poziomie. Potwierdzenie, że hurtownia danych nie łamie zapytań analitycznych z powodu braku klucza w źródle.
- **Potwierdzenie:**

BUSINESS EXCEPTION REPORT (Keys mapped to -999999)

	table_name	row_count	foreign_key	orphan_count	orphan_percentage
0	fact_refund_item	1132	id_claim	1131	99.91
1	fact_payment	2235	id_discount	2167	96.96
2	fact_payment	2235	id_client	1681	75.21
3	fact_refund_item	1132	id_client	844	74.56
4	fact_payment	2235	id_delivery	974	43.58
5	fact_refund_item	1132	id_location	354	31.27
6	fact_payment	2235	id_location	678	30.34
7	fact_payment	2235	id_site	403	18.03
8	fact_refund_item	1132	id_site	92	8.13
9	fact_delivery_item	1741	id_delivery_man	103	5.92
10	fact_order_item	9454	id_planner_item	392	4.15

7. Testy Akceptacyjne, Funkcjonalne i End-to-End

7.1 Weryfikacja Historyzacji Danych

- **Cel:** Potwierdzenie poprawnego działania mechanizmu Slowly Changing Dimensions Typu 2 w celu zachowania prawdy historycznej.
- **Kroki:** Symulacja zmiany nazwiska klienta w bazie operacyjnej, przetworzenie danych przez Dataform i odpytanie hurtowni zapytaniem SQL dla `id_customer = 1` sortując po dacie aktualizacji.
- **Oczekiwany wynik:** Dwa rekordy dla tego samego klienta: stary ze zgaszoną flagą `is_current = FALSE` (oraz zamkniętą datą `valid_to`) i nowy z flagą `is_current = TRUE` oraz zaktualizowanym nazwiskiem.
- **Potwierdzenie:**

	id_customer	name	is_current	valid_from	valid_to
0	1	Jan Nowak - ZMIENIONE DO TESTU	True	2026-06-15 08:26:22.404190+00:00	9999-12-31 23:59:59+00:00
1	1	Jan Nowak	False	2025-05-22 09:48:35.269474+00:00	2026-06-15 08:26:22.404190+00:00

7.2 Test Filtrowania Przestrzennego


- **Cel:** Weryfikacja poprawności czyszczenia danych konkurencji o własne placówki. Zewnętrzne API (Google Maps) mogłoby zwracać własne piekarnie jako placówki w tej samej okolicy.

- **Kroki:** Skrypt sprawdzający analizuje kartezjańskie złączenie gotowych tabel `dim_site` oraz `dim_competitor` w warstwie Gold z nałożonym warunkiem dystansu GIS (`ST_DISTANCE < 30.0m`).
- **Oczekiwany wynik:** Zwrócona pusta tabela, co bezsprzecznie potwierdza poprawność odrzucenia z bazy konkurencji punktów nakładających się na nasze sklepy.
- **Potwierdzenie:**

```
id_competitor competitor_name id_site our_site_name distance_meters
```


7.3 Potwierdzenie całościowego działania systemu

- **Cel:** Udowodnienie, że nowo pojawiające się zdarzenie biznesowe przepływa poprawnie przez całą architekturę aż do widoku dla użytkownika końcowego.
- **Kroki:**
 1. Zanotowanie aktualnej wartości sprzedaży na raporcie Looker Studio.
 2. Wgranie do GCS pliku Parquet symulującego gigantyczną transakcję (np. wartość 500 PLN).
 3. Uruchomienie przeliczenia modelu (Dataform).
 4. Odświeżenie raportu końcowego.
- **Oczekiwany wynik:** Wskazania na wykresie/dashboardzie w Looker Studio powinny natychmiast uwzględnić nową transakcję, zwiększając łączną sumę o dokładnie 500 PLN.
- **Potwierdzenie:**



Select date range

Procentowy podział przychodów na dni tygodnia



Przychody na przestrzeni czasu

Przychód

193,757.75 zł

Średnia wartość zamówienia

33.76 zł

8. Dokumentacja wykorzystania narzędzi AI

W trakcie realizacji projektu korzystaliśmy z narzędzia Claude Code (Anthropic) jako asystenta. Poniżej uczciwa ocena zakresu wykorzystania.

Co było własną pracą i koncepcją

- **Decyzja o integracji danych pogodowych** - wynikła bezpośrednio z rozmowy z klientem (mechanizm "zamówienia na płocie"); pomysł i uzasadnienie biznesowe są nasze
- **Wybór prognozy D-1 zamiast danych historycznych** - decyzja analityczna podjęta po zrozumieniu problemu: klient decyduje o zakupie na podstawie prognozy, nie rzeczywistości
- **Wybór okna 6–10 rano** - decyzja biznesowa
- **Decyzja o denormalizacji danych pogodowych do FACT_ORDER_ITEM** - po odrzuceniu przez nas propozycji DIM_SITE daily i BRIDGE_WEATHER_DAILY
- **Koncepcja i uzasadnienie wszystkich czterech raportów** (5.1–5.4), w tym pomysł heat mapy z bucketami i świadome zastrzeżenie metodologiczne dot. jednorodności zaludnienia
- **Architektura ELT** (GCS → BigQuery → Dataform) - decyzja projektowa, korekta z ETL na ELT
- **Tworzenie wykresów w Looker Studio oraz zapytań SQL będących ich źródłami** - implementacja i konfiguracja wizualizacji dla wszystkich raportów

Co wykonał Claude

- **Skrypty Python** do eksploracji API open-meteo (testy granulacji ICON-D2, skrypt prognozy porannej, skrypt D-1) oraz pierwsza wersja zwięzłego skryptu fetchującego pogodę zgodna z dokumentacją - kod pisany przez Claude, uruchamiany i weryfikowany przez nas
- **Research dokumentacji open-meteo** - odkrycie że `historical-forecast-api` to blend, nie D-1; znalezienie `previous-runs-api` i parametru `previous_model_run`
- **Naprawa bugów** w skryptach (błędne etykiety godzin w oknie 6–10)

- **Research progów klasyfikacji** WEATHER_MORNING_WAS_RAINY na podstawie literatury WMO/NWS (56 źródeł) - progi 50%/1.0mm/2.5mm zaproponowane przez Claude
- **Diagnoza i naprawa błędów SQL i BigQuery** - m.in. brakujące funkcje (STR , INT , DATEPART), obsługa STRUCT w porównaniach, format daty, ograniczenia CREATE TEMP FUNCTION w Looker Studio
- **Skrypt Cloud Function** pobierający dane z open-meteo dla rekordów bez pogody i aktualizujący FACT_ORDER_ITEM - kod, requirements.txt , konfiguracja klienta BigQuery, integracja z Cloud Scheduler
- **Wyjaśnienia konceptualne i architektoniczne** (Scheduled Queries vs Cloud Functions, hierarchie flat/snowflake/bridge, typy miar, SCD2, standardy branżowe przy decyzjach architektonicznych) - Claude tłumaczył, my podejmowaliśmy decyzje
- **Wsparcie implementacyjne** - przyspieszenie pisania kodu (podpowiedzi składni, gotowe fragmenty do adaptacji) oraz nawigacja po interfejsach GCP i Looker Studio (gdzie co kliknąć)
- **Looker Studio** - nauka obsługi narzędzia, połączenie hurtowni BigQuery jako źródła danych (custom query, parametry @DS_START_DATE), pola kalkulowane CASE WHEN dla wartości binarnych, diagnoza date range control
- **Edycja i formatowanie tekstu** w docs/km2.md - formatowanie tabel CSV, poprawa sekcji 2.1 (urwane zdanie), korekta opisu harmonogramu, dodanie zdania o bucketach w 5.3
- **Wspólne redagowanie dokumentacji** - Claude współtworzył i edytował treść dokumentacji projektowej, w tym niniejszy dokument
- **Pomoc przy google cloud** - przy połapaniu się w możliwościach i UI oraz permisjach na google cloud

Co wykonał Jakub

- **Model fizyczny** (model.drawio) i iteracyjne dostosowywanie struktury Star/Constellation Schema
- **Skrypty Google Maps API** (testy, pobieranie danych POI z FieldMask i filtrami kategorii)
- **Cały pipeline Dataform** (bronze/silver/gold): surrogate keys, SCD2, spatial joins z danymi konkurencji, metryki odległościowe w DIM_CUSTOMER
- **Wszystkie wymiary i tabele faktów** oraz bridge tables, widoki SQL analityczne, null rows
- **Struktura projektu** i organizacja plików oraz drobna pomoc przy lookerze

Co wykonał Adam

- **Prace przygotowawcze i rozmowa z klientem** (wspólnie z Jakubem)
- **Moduł open-meteo**: skrypty Python pobierające prognozy D-1, Cloud Function doładowująca dane pogodowe do FACT_ORDER_ITEM, integracja z Cloud Scheduler
- **Kolumny pogodowe w modelu** i logika klasyfikacji WEATHER_MORNING_WAS_RAINY
- **Warstwa raportowa w Looker Studio**: wszystkie cztery raporty, połączenie BigQuery, pola kalkulowane, heat mapy, wykresy punktowe, date range control